

基于神经网络的模糊自适应 PID 控制方法*

李 卓 萧德云 何世忠

(清华大学自动化系·北京, 100084)

摘 要 提出一种基于 BP 神经网络的模糊自适应 PID 控制器。该控制器综合模糊控制、神经网络与 PID 调节各自的优点,既具有模糊控制的简单和有效的非线性控制作用,又具有神经网络的学习和适应能力,同时具备 PID 控制的广泛适应性,仿真实验表明该控制器对模型、环境具有较好的适应能力和较强的鲁棒性。

关键词 神经网络,模糊控制,自适应 PID 控制

1 引 言

在工业过程控制的发展史上,PID 控制是历史最悠久、生命力最强的控制方式。即使在美、日等工业发达国家,采用高级控制技术的回路数也只占很小的比例,90%以上的控制回路基本上还是采用 PID 控制器,可见 PID 控制在工业过程控制中占据非常重要的地位。因此,PID 控制器的智能化是工业过程控制智能化的重要组成部分。

本文提出一种基于神经网络的模糊自适应 PID 控制方案,利用模糊逻辑的“概念”抽象能力和非线性处理能力,利用神经网络的自学习能力和任意函数的逼近能力,通过两者的有机结合寻找一个最佳的 P、I、D 非线性组合控制规律。仿真实验表明这样的控制系统能够实现对未知对象进行在线控制,并具备适应控制环境变化的能力和自学习能力。

2 基于 BP 神经网络的模糊自适应 PID 控制器

控制问题就是根据从动力学系统中获得的信息以确定为实现预定目标所必需的控制输入量,因此控制也可看作是模式识别的问题,控制器即完成一个模式分类器的映射功能:从其输入——量测的系统状态变化信号得到其输出——相应的控制作用^[1]。考虑到 BP 神经网络具有函数逼近的功能,它可用于实现这种控制器。

连续 PID 控制算式为

$$u(t) = K_p \left[e(t) + \frac{1}{T_i} \int_0^t e(t) dt + T_d \frac{de(t)}{dt} \right] \quad (1)$$

相应的增量式数字 PID 控制算式

$$\begin{aligned} u(t) = & u(t-1) + K_p[e(t) - e(t-1)] + K_i e(t) \\ & + K_d[e(t) - 2e(t-1) + e(t-2)] \end{aligned} \quad (2)$$

式中 K_p 、 K_i 、 K_d 分别为比例、积分、微分系数, $K_i = K_p \frac{T}{T_i}$, $K_d = K_p \frac{T_d}{T}$, T 为采样周期。

比例、积分、微分三种控制作用对获得良好的控制都是必要的,但还不是充分的条件。如果跳出 P、I、D“线性组合”的结构,就有可能找到某种非线性组合的最佳控制规律。我们让 BP 网

* 国家自然科学基金资助项目

络来完成此项任务,通过网络自身的学习,找到某一最优控制律下的 P、I、D 参数。

神经网络—模糊自适应 PID 控制系统结构如图 1 所示。它包括四个部分:

1) 传统 PID 控制器:直接对过程构成闭环控制;

2) 模糊量化模块:对系统的状态变量进行归档模糊量化和归一化处理^[2]。其优点是:① 可以利用模糊控制的鲁棒性和非线性控制作用;② 相当于对 NN2 神经网络的输入进行预处理,避免了当神经网络的激活函数用 Sigmoid 函数或双曲正切函数时,由于输入过大易导致输出趋于饱和,使得对输入不再敏感;

3) 辨识网络 NN1: 用于建立被控系统的辨识模型,为 NN2 提供所需变量 $\frac{\partial y}{\partial u}$;

4) 神经网络 NN2: 根据系统的状态,调节 PID 控制器的参数以期达到某种性能指标的最优。具体实现方法是使神经元的输出状态对应于 PID 控制器的被调参数 K_p 、 K_i 、 K_d ,便可通过网络自身权系数的调整,使得其稳定状态对应于某种最优控制律下的 PID 控制器参数。

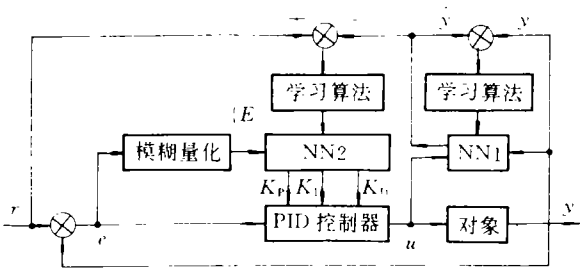


图 1 基于神经网络的模糊自适应 PID 控制系统

3 自适应 PID 控制器算法实现

3.1 归档模糊量化

对系统状态变量 $\{e(t)\}$ 进行“归档”模糊量化、归一化处理。系统误差为 $e(t) = r(t) - y(t)$,通过计算 e/r 将系统误差归一化,并将其在闭区间 $[0,1]$ 内分成若干等级,完成“归档”模糊量化。例^[3]

$$E = \begin{cases} 5\text{sgn}(e) & |e/r| \geq 0.8 \\ 4\text{sgn}(e) & |e/r| \geq 0.5 \\ 3\text{sgn}(e) & |e/r| \geq 0.3 \\ 2\text{sgn}(e) & |e/r| \geq 0.1 \\ 1\text{sgn}(e) & |e/r| \geq 0.03 \\ 0 & |e/r| < 0.03 \end{cases} \tag{3}$$

E 为系统误差的模糊论域,再乘以一个缩减系数将其调至 $0 \sim 1$ 的数量级,即将误差 e 转化成“概念”值,送给神经网络 NN2。

3.2 辨识网络 NN1

设被控对象是单输入—单输出非线性系统

$$y(t) = f[y(t-1), \dots, y(t-n), u(t-1), \dots, u(t-m)] \tag{4}$$

其中 y, u 分别是系统的输出和输入, n, m 分别为 $\{y(t)\}$ 和 $\{u(t)\}$ 的阶次, $f(\cdot)$ 是非线性函数。

设用来辨识对象特性的神经网络 NN1 是一个具有 $(n+m)$ 个输入节点, r 个隐节点, 1 个输出节点的三层神经网络,如图 2 所示。为了非线性系统辨识的方便,将输出层激活函数取线性函数,隐层激活函数取双曲正切函数。对系统辨识采用的是串并联辨识模型,同时结合离线训练和在线训练的方法。将时间序列 $\{y(t)\}$ 和 $\{u(t)\}$ 作为模式特征,网络的输入层为对象经过

时延的输出 $y(t-i)$ 和输入 $u(t-i)$ 。

$$O_i^{(l)}(t) = \begin{cases} y(t-i) & 0 \leq i \leq n-1 \\ u(t-i+n) & n \leq i \leq n+m-1 \end{cases} \tag{5}$$
$$O_{(n-m)}^{(l)}(t) \equiv 1$$

网络的隐层为

$$I_j^{(h)} = \sum_{i=0}^{n-m} V_{ji} O_i^{(l)} \quad j = 0, 1, \dots, r-1 \tag{6}$$

$$O_j^{(h)}(t) = f[I_j^{(h)}(t)] \tag{7}$$

$$O_R^{(h)} \equiv 1$$

其中 $\{V_{ji}\}$ 为隐层权系数, $V_{j(n-m)} = \theta_j$ 为阈值, $f(x)$ 为激活函数, 取 $f(x) = \frac{1-e^{-x}}{1+e^{-x}}$, 上标 (l) 、 (h) 分别代表输入层、隐层。网络的输出层为

$$\hat{y}(t+1) = \sum_{j=0}^r W_j O_j^{(h)}(t) \tag{8}$$

其中 $\{W_j\}$ 是输出层权系数, W_r 是阈值, 输出节点是线性节点。利用 BP 学习算法来修正权及阈值, 使指标函数

$$J_I = \frac{1}{2} \sum_p [y(t+1) - \hat{y}(t+1)]^2 \tag{9}$$

最小化, 可得相应的修正公式为

$$\Delta W_j(t+1) = \alpha [(y(t+1) - \hat{y}(t+1)) O_j^{(h)}(t) + \beta \Delta W_j(t)] \quad j = 0, 1, \dots, r \tag{10}$$

$$\Delta V_{ji}(t+1) = \alpha [(y(t+1) - \hat{y}(t+1)) f'(I_j^{(h)}(t)) W_j(t) O_i^{(l)}(t) + \beta \Delta V_{ji}(t)] \tag{11}$$
$$j = 0, \dots, (n+m)$$

其中 α 为学习率, β 为惯性系数。给梯度加惯性项可避免学习过程的振荡, 使学习率可取较大值, 从而加速收敛 α, β 的值均在 $(0, 1)$ 上, 且由 $f'(x)$ 知 $f'(x) = [1 - f^2(x)]/2$ 。




图 2 NN1 神经网络结构图




图 3 NN2 神经网络结构图

3.3 自适应神经网络 NN2

可以用 $G(\cdot)$ 描述(2)式的右侧

$$u(t) = G[u(t-1), K_p, K_i, K_d, e(t), e(t-1), e(t-2)] \tag{12}$$

$G(\cdot)$ 是与 $K_p, K_i, K_d, e(t), u(t-1), y(t)$ 等有关的非线性函数, 我们用 BP 网络 NN2 通过训练和学习来找到这样一个最佳控制规律。

设 NN2 是一个三层 BP 网络, 如图 3 所示, 有 S 个输入节点, H 个隐层节点, 3 个输出节点。

NN2 的输出节点分别对应 PID 控制器的三个参数 K_p, K_i, K_d , 因为它们不能为负值, 所以输出层激活函数取 Sigmoid 函数, 隐层激活函数仍取双曲正切。网络 NN2 的输入为经过模糊量化处理后的系统状态变量

$$O_i^{(1)} = E(t - i) \quad i = 0, 1, \dots, (S - 1) \quad (13)$$

$$O_i^{(1)} \equiv 1$$

S 为输入变量的个数, 取决于被控系统的复杂程度。网络隐层为

$$I_j^{(2)}(t) = \sum_{i=0}^S V_{ji} O_i^{(1)}(t) \quad (14)$$

$$O_j^{(2)}(t) = f[I_j^{(2)}(t)] \quad j = 0, 1, 2, \dots, (H - 1) \quad (15)$$

$$O_H^{(2)} \equiv 1$$

其中 $\{V_{ji}\}$ 为隐层权系数, $V_{ji} = \theta_j$ 为阈值, 上标 (1)、(2)、(3) 分别代表输入层、隐层、输出层, $f(x)$ 为双曲正切型激活函数。网络的输出层有三个节点

$$I_k^{(3)}(t) = \sum_{j=0}^H W_{kj} O_j^{(2)}(t) \quad k = 0, 1, 2 \quad (16)$$

$$O_k^{(3)}(t) = g[I_k^{(3)}(t)] \quad (17)$$

即

$$O_1^{(3)}(t) = K_p, \quad O_2^{(3)}(t) = K_i, \quad O_3^{(3)}(t) = K_d \quad (18)$$

其中 $\{W_{kj}\}$ 是输出层权系数, $W_{kH} = \theta_k$ 为阈值, $g(x)$ 为 Sigmoid 函数, 即 $g(x) = \frac{1}{1 + e^{-x}}$ 。取性能指标

$$J_c = \frac{1}{2} \sum_p [r(t+1) - y(t+1)]^2 \quad (19)$$

p 为学习长度。用最陡下降法修正网络的权系数

$$\Delta W_{kj}(t+1) = -\eta \frac{\partial J_c}{\partial W_{kj}} + \gamma \Delta W_{kj}(t) \quad (20)$$

η 为学习速率, γ 为惯性系数, 而

$$\frac{\partial J_c}{\partial W_{kj}} = \frac{\partial J_c}{\partial y(t+1)} \cdot \frac{\partial y(t+1)}{\partial u(t)} \cdot \frac{\partial u(t)}{\partial O_k^{(3)}(t)} \cdot \frac{\partial O_k^{(3)}(t)}{\partial I_k^{(3)}(t)} \cdot \frac{\partial I_k^{(3)}(t)}{\partial W_{kj}} \quad (21)$$

注意这里需要用到变量 $\frac{\partial y(t+1)}{\partial u(t)}$, 当对象特性未知时, $\frac{\partial y(t+1)}{\partial u(t)}$ 难于求得, 可用辨识网络 NN1 的输出 $\hat{y}(t+1)$ 来近似 $y(t+1)^{[4,5]}$, 用 $\frac{\partial \hat{y}(t+1)}{\partial u(t)}$ 来近似 $\frac{\partial y(t+1)}{\partial u(t)}$ 。可由 NN1 辨识网络中 (5)~(9) 式求得, 即

$$\frac{\partial \hat{y}(t+1)}{\partial u(t)} = \sum_{j=0}^R \frac{\partial \hat{y}(t+1)}{\partial O_j^{(h)}(t)} \cdot \frac{\partial O_j^{(h)}(t)}{\partial I_j(t)} \cdot \frac{\partial I_j(t)}{\partial u(t)} = \sum_{j=0}^R W_{j(t)} \cdot f[I_j(t)] \cdot V_{jn}(t) \quad (22)$$

由 (2) 式得

$$k = 1 \text{ 时, 对应 } K_p, \quad \frac{\partial u(t)}{\partial O_1^{(3)}(t)} = e(t) - e(t-1) \quad (23)$$

$$k = 2 \text{ 时, 对应 } K_i, \quad \frac{\partial u(t)}{\partial O_2^{(3)}(t)} = e(t) \quad (24)$$

$$k = 3 \text{ 时, 对应 } K_d, \quad \frac{\partial u(t)}{\partial O_3^{(3)}(t)} = e(t) - 2e(t-1) + e(t-2) \quad (25)$$

这样, 可得 NN2 网络输出层权系数

$$\Delta W_{kj}(t+1) = \eta \delta_k O_j^{(2)}(t) + \gamma \Delta W_{kj}(t) \quad j = 0, 1, \dots, H \quad (26)$$

$$\delta_k = e(k+1) \cdot \frac{\partial \hat{y}(t+1)}{\partial u(t)} \cdot \frac{\partial u(t)}{\partial O_k^{(3)}(t)} \cdot g'[I_k^{(3)}(t)] \quad k = 0, 1, 2 \quad (27)$$

同理可得隐层权系数

$$\Delta V_{ji}(t+1) = \eta \delta_j O_i^{(1)}(t) + \gamma \Delta V_{ji}(t) \quad i = 0, 1, 2, 3 \quad (28)$$

$$\delta_j = f'(I_j^{(2)}(t)) \sum_{k=1}^3 \delta_k W_{kj} \quad j = 0, 1, 2, \dots, (H-1) \quad (29)$$

且 $g'(x) = g(x)[1 - g(x)], \quad f'(x) = [1 - f^2(x)]/2$

3.4 控制算法

综上所述,自适应PID控制算法可表述如下:

- 1) 通过采样得到 $y(t)$ 、 $r(t)$, 然后计算 $e(t)$;
- 2) 经模糊量化归档处理;
- 3) 根据(13)~(18)式计算神经网络NN2的各层神经元输入和输出, NN2的输出对应PID控制器三个参数;
- 4) PID控制器的输出 $u(t)$ 同时送对象及神经网络NN1, 产生下步输出 $y(t+1)$;
- 5) 用(5)~(8)式计算神经网络NN1的各层神经元输入和输出, NN1网络的输出为 $\hat{y}(t+1)$, 网络NN1的目标值为对象的实际输出 $y(t+1)$;
- 6) 由 $[y(t+1) - \hat{y}(t+1)]$ 产生的偏差按(10)、(11)式修正NN1网络的权值及阈值;
- 7) 由系统期望给定 $r(t+1)$ 与对象实际输出 $y(t+1)$ 之间的偏差 $e(t) = r(t) - y(t)$, 逐层反传修正网络NN2的权值及阈值, 具体步骤为:

- ① 由(22)式计算 $\frac{\partial \hat{y}(t+1)}{\partial u(t)}$;
- ② 按(27)式计算等效误差 δ_k ;
- ③ 根据(26)式修正NN2输出层的权值;
- ④ 由(29)式计算隐层的等效误差 δ_j ;
- ⑤ 按(28)式修正隐层的权系数;
- 8) 令 $t = t+1$, 将 $\{y(t)\}$ 、 $\{u(t)\}$ 和 $\{e(t)\}$ 移位处理后返回1)。

4 仿真研究

考虑被控对象是参数时变的非线性系统

$$y(t+1) = a_0(t) \frac{y(t)}{1 + y^2(t)} + u(t) \quad (30)$$

$a_0(t)$ 为有界时变参量, 故取 $a_0(t) = 5(1 - 0.8e^{-0.1t})$ 。NN1网络结构为4—6—1, NN2网络结构为3—8—3, 且取参数 $\alpha = 0.1, \beta = 0.3, \eta = 0.3, \gamma = 0.3$ 。网络NN2的初始权值取区间 $[-0.5, 0.5]$ 上的随机数, 当然最好初始权值有一定的先验知识, 以减少开始学习时控制量有大的波动。此例中 $p = 50$, 即每50步学习一次。图4(a)为系统阶跃响应, 图4(b)为PID控制器参数的调整情况。可以看出, 对于参量为有界时变的非线性对象, 神经网络—模糊自适应PID控制器仍然具有较好的鲁棒性。




图 4 参数为有界时变的非线性系统输出响应

5 结 论

本文采用神经网络与模糊系统相结合的方式,构造了一种自适应 PID 控制器。该控制器综合模糊控制、神经网络与 PID 调节各自的长处,既具有模糊控制简单有效的非线性控制作用,又具有神经网络的学习和适应能力,同时具有 PID 调节的广泛适应性。该方法的有效性得到仿真实验的证明,其突出优点是:不需要知道受控对象的结构和参数;抑制噪声干扰能力强;适应性和鲁棒性强;结构简单,易于实现。

参 考 文 献

- 1 田明,戴汝为. 神经网络控制系统. 信息与控制,1992,21(3):156—161
- 2 李卓. 模糊自适应 PID 控制方法的研究. 清华大学硕士学位论文,1995
- 3 李友善. Fuzzy 控制理论在甜菜制糖过程的应用. 自动化学报,1994,20(3):334—337
- 4 Nielson H R. Theory of the backpropagation neural network. IEEE IJCNN, 1989, (1):593—606
- 5 谭永红. 基于 BP 神经网络的自适应控制. 控制理论与应用,1994,11(1):84—88

A Fuzzy Adaptive PID Controller Based on Neural Network

Li Zhuo, Xiao Deyun, He Shizhong

(Tsinghua University)

Abstract A fuzzy adaptive PID controller based on BP neural network is proposed in this paper. It is a result of the comprehensive combination of fuzzy control, neural network, and PID controller. It possesses not only the simplicity and the nonlinear control ability of fuzzy control, but also the learning and adaptive functions by using neural network. Furthermore, the controller is as widely adaptive as PID regulation. We have thus proven that this controller has adaptability and robustness to environments.

Key words neural network, fuzzy control, adaptive PID control

作 者 简 介

李 卓 女,1982年毕业于鞍山钢铁学院并获学士学位。毕业后在鞍钢职工工学院任教,1995年在清华大学自动化系获硕士学位。研究方向为模糊控制、神经网络控制和计算机控制等。

萧德云 1970年毕业于清华大学,现为清华大学自动化系教授。主要从事过程控制系统、辨识建模、故障诊断、计算机应用和大型连续过程工业 CIMS 等的研究与教学工作。

何世忠 教授,1970年毕业于清华大学,1982年获清华大学硕士学位,1989年赴新加坡国立大学从事科学研究三年。主要研究方向为过程控制、模糊控制等。